# Documento de pruebas — Actividad 6

Componente: agrupamiento no supervisado (K-Means y jerárquico) de las estaciones del Sistema Experto de Rutas TransMilenio. Repositorio: https://github.com/harold474/Transmilenio.

## 1. Entorno de pruebas

| | |
|---|---|
| Sistema operativo | Windows (win32) |
| Python | 3.14.3 |
| pytest | 9.1.1 (pluggy 1.6.0) |
| Librerías del modelo | pandas, numpy, scikit-learn, matplotlib (requirements.txt) |

## 2. Pruebas automatizadas (pytest -v)

Se ejecutó *pytest -v* en la raíz del proyecto: **20 pruebas, 20 aprobadas** en 3.72 s (8 nuevas del agrupamiento + 4 del modelo supervisado + 8 del sistema experto).

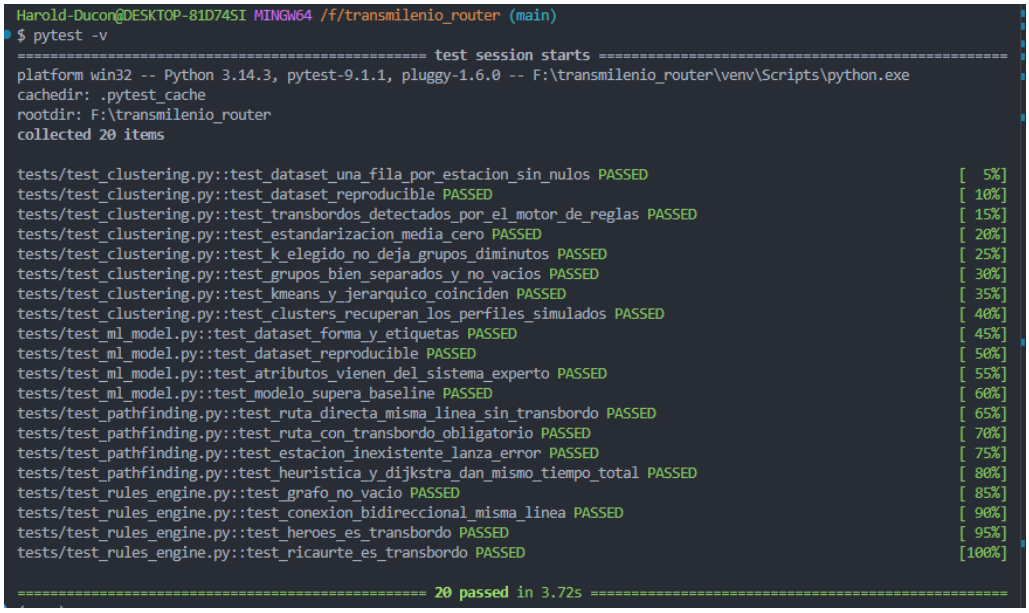



Figura 1. Salida de pytest -v.

## 2.1 Casos de prueba del agrupamiento (tests/test_clustering.py)

| Caso | Qué verifica | Resultado |
|---|---|---|
| test_dataset_una_fila_por_estacion_sin_nulos | Una fila por cada estación de la red, sin repetidas y sin valores nulos en los atributos. | PASSED |
| test_dataset_reproducible | Dos generaciones con la misma semilla producen el mismo dataset. | PASSED |
| test_transbordos_detectados_por_el_motor_de_reglas | Heroes y Ricaurte tienen 2 o más líneas y PortalUsme tiene 1 (atributos tomados del motor de reglas). | PASSED |
| test_estandarizacion_media_cero | Tras estandarizar, cada atributo tiene media 0 y desviación 1. | PASSED |

| Caso | Qué verifica | Resultado |
|---|---|---|
| test_k_elegido_no_deja_grupos_diminutos | El k elegido está entre 2 y 8 y su grupo más pequeño tiene al menos 3 estaciones. | PASSED |
| test_grupos_bien_separados_y_no_vacios | Se forman exactamente k grupos no vacíos y la silueta supera 0.4. | PASSED |
| test_kmeans_y_jerarquico_coinciden | K-Means y el método jerárquico concuerdan (ARI mayor a 0.8). | PASSED |
| test_clusters_recuperan_los_perfiles_simulados | Los grupos recuperan los perfiles simulados (ARI mayor a 0.8). | PASSED |

Las 12 pruebas anteriores (sistema experto y modelo supervisado) siguen aprobadas, lo que confirma que el nuevo componente no rompió lo existente.

## 3. Pruebas manuales: ejecución del agrupamiento

Comando: `python src/clustering.py`. La salida completa queda en docs/resultados_clustering.txt y los grupos en data/estaciones_clusters.csv.

## 3.1 Selección de k (K-Means)

| k | Inercia | Silueta | Estaciones del grupo más pequeño |
|---|---|---|---|
| 2 | 136.359 | 0.563 | 5 |
| 3 | 88.299 | 0.475 | 5 |
| **4** | **47.544** | **0.635** | **5** |
| 5 | 25.276 | 0.647 | 1 |
| 6 | 14.530 | 0.659 | 1 |
| 7 | 10.505 | 0.631 | 1 |
| 8 | 8.458 | 0.489 | 1 |

La silueta sola prefiere k = 6, pero ese valor deja estaciones aisladas en grupos de una sola estación (Heroes y Calle146), que no sirven para segmentar la red. Por eso se eligió el mayor valor de silueta entre los k cuyo grupo más pequeño tiene al menos 3 estaciones: **k = 4**.

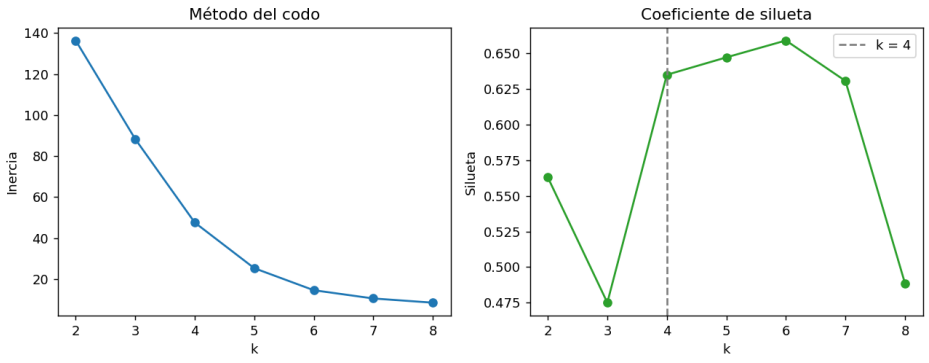



Figura 2. Método del codo y coeficiente de silueta.

## 3.2 Calidad del agrupamiento

| Métrica | Valor |
|---|---|
| Silueta K-Means | 0.635 |
| Silueta jerárquico (Ward) | 0.635 |
| Davies-Bouldin K-Means | 0.578 (menor es mejor) |
| ARI K-Means vs jerárquico | 1.000 |
| ARI K-Means vs perfil latente simulado (validación) | 1.000 |
| Varianza explicada por PCA (2 componentes) | 81.9 % |

## 3.3 Perfil de cada grupo (promedios en unidades originales)

| Grupo | N | Líneas | Vecinos | Interm. | Dist. centro (km) | Pico AM | Pico PM | Valle | Fin sem. |
|---|---|---|---|---|---|---|---|---|---|
| C0 Intermedias | 14 | 1.0 | 2.00 | 0.09 | 7.77 | 5.15 | 4.98 | 3.76 | 3.09 |
| C1 Centro | 8 | 1.0 | 1.88 | 0.13 | 3.56 | 6.66 | 15.80 | 9.99 | 6.25 |
| C2 Nodos de transbordo | 5 | 2.4 | 3.40 | 0.38 | 4.08 | 17.59 | 18.47 | 14.58 | 10.29 |
| C3 Portales | 6 | 1.0 | 1.00 | 0.00 | 11.88 | 17.03 | 4.94 | 5.92 | 6.49 |

Demanda en miles de pasajeros por día (simulada). Interm. = intermediación.

## 3.4 Estaciones por grupo

| Grupo | Estaciones |
|---|---|
| C0 Intermedias | Alcala, Banderas, BibliotecaTintal, Boyaca, Calle100, Calle106, Calle85, ElPolo, HumedalCordoba, Molinos, Quirigua, Sena, SubaTV91, Tunal |
| C1 Centro | Calle72, Consuelo, CountrySur, MinutoDeDios, MuseoDelOro, Normandia, TercerMilenio, Universidades |
| C2 Nodos de transbordo | AvenidaJimenez, Calle146, Heroes, Ricaurte, SimonBolivar |
| C3 Portales | Portal80, PortalAmericas, PortalNorte, PortalSuba, PortalSur, PortalUsme |

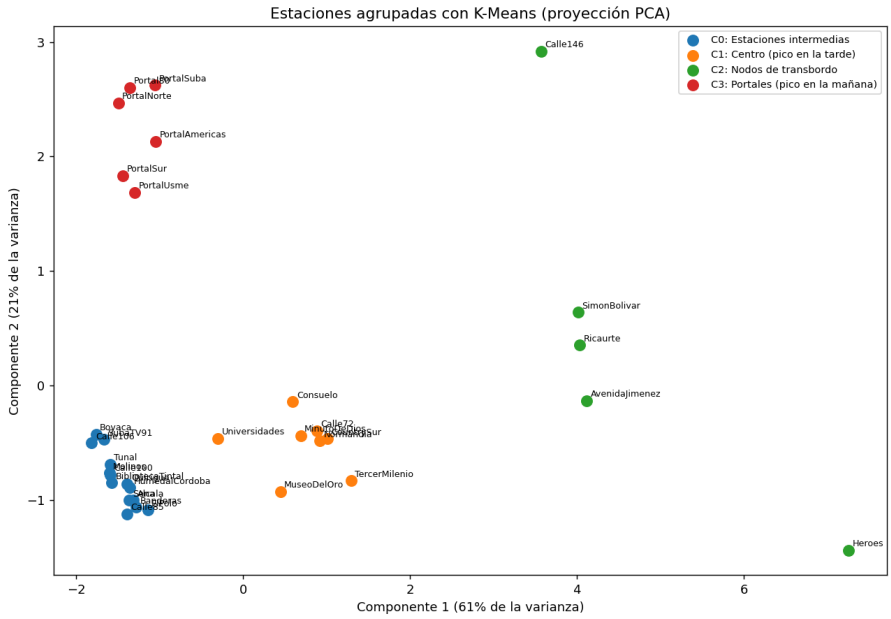



Figura 3. Estaciones agrupadas con K-Means, proyección PCA.

## 4. Análisis de resultados

- Los cuatro grupos son interpretables: portales (extremos de línea con pico en la mañana), centro (pico en la tarde), nodos de transbordo (varias líneas y demanda alta todo el día) e intermedias (baja demanda).
- Dos algoritmos distintos (K-Means y Ward) producen exactamente los mismos grupos (ARI = 1.0), lo que da confianza en que la estructura no depende del método.
- En la proyección PCA los grupos aparecen separados, con 81.9 % de la varianza explicada en dos componentes. Heroes queda muy alejado porque combina más líneas, más vecinos y la mayor intermediación de la red.
- Los nodos de transbordo coinciden con las estaciones que detecta el motor de reglas, lo que conecta este componente con el sistema experto de la actividad 2.

## 5. Limitaciones

La demanda por franja es sintética y se generó a partir de los mismos perfiles que luego se recuperan (ARI contra el perfil simulado = 1.0). Los resultados validan el código, pero no demuestran que esos grupos existan en la demanda real. Además son solo 33 estaciones, así que cambiar un grupo modifica los resultados. Para una evaluación real se deben reemplazar las columnas de demanda por validaciones de TransMilenio S.A. o de Datos Abiertos Bogotá.